



TRABAJO FIN DE MÁSTER
MÁSTER UNIVERSITARIO OFICIAL EN CIENCIA DE DATOS
E INGENIERÍA DE COMPUTADORES

Sistemas de recomendación de películas para grupos

Autor

Juan José Sierra González

Director

Juan Manuel Fernández Luna



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, enero de 2020

Sistemas de recomendación de películas para grupos

Autor

Juan José Sierra González

Director

Juan Manuel Fernández Luna

Sistemas de recomendación de películas para grupos

Juan José Sierra González

Palabras clave: incluir palabras clave...

Resumen

Incluir resumen...

Group recommender systems for movies

Juan José Sierra González

Keywords: include keywords...

Abstract

Include abstract...

Yo, **Juan José Sierra González**, alumno del Máster Universitario Oficial en Ciencia de Datos e Ingeniería de Computadores de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 76589592Y, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Máster en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Juan José Sierra González

Granada a 9 de enero de 2020.

D. **Juan Manuel Fernández Luna**, Profesor del Área de Uncertainty Treatment in Artificial Intelligence del Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

Informa:

Que el presente trabajo, titulado ***Sistemas de recomendación de películas a grupos***, ha sido realizado bajo su supervisión por **Juan José Sierra González**, y autoriza la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expide y firma el presente informe en Granada a 9 de enero de 2020.

El director:

Juan Manuel Fernández Luna

Agradecimientos

Incluir agradecimientos...

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
2. Planificación	5
2.1. Requisitos de investigación	5
2.2. Planificación del trabajo	7
2.2.1. Estimación de coste de materiales e infraestructura . .	7
2.2.2. Distribución de tiempo entre tareas	8
3. Revisión de la literatura: estado del arte	11
3.1. Análisis de la literatura	11
3.1.1. Historia de los sistemas de recomendación	11
3.1.2. Recomendación a grupos en la actualidad	13
3.2. Propuesta del estado del arte escogida	16
Bibliografía	20

Índice de figuras

Índice de tablas

Capítulo 1

Introducción

En la actualidad, la informática juega un papel fundamental en el día a día de la mayoría de personas. No solo en el ámbito profesional, donde ya lleva más años asentada, sino que cada vez es más común encontrar soluciones informáticas en problemas de la vida cotidiana. Donde antes podían requerirse varios minutos de búsqueda entre páginas de enciclopedias, ahora se resuelven consultas de todo tipo en cuestión de segundos gracias a los grandes volúmenes de información que se almacenan en Internet, y que comparten (y amplían) a diario millones de usuarios.

Pero la información no siempre se presenta de forma clara y concisa, y a menudo se acumulan enormes cantidades de datos aparentemente inservibles. Sin embargo, mediante el manejo de tan grandes cantidades de dichos datos se puede obtener información útil que de otra forma sería prácticamente imposible de detectar. La **ciencia de datos**, encargada de obtener toda esa información compleja, abundante y difusa y transformarla en información útil, está siendo utilizada cada vez con más asiduidad para todo tipo de finalidades. Este estudio se centrará en su aplicación para **recomendar** elementos a los usuarios, o lo que más comúnmente se conoce como **sistemas de recomendación**.

1.1. Motivación

Los sistemas de recomendación ya forman parte de la gran mayoría de plataformas web que ofrecen bienes o servicios. Mientras un usuario ojea un elemento de un catálogo en una página web es habitual que encuentre las secciones de “Productos similares” y “Productos recomendados”. Mientras que la primera se basa puramente en características comunes entre los elementos, la segunda es **una recomendación personalizada** para cada usuario.

Debido a que las empresas generan beneficio directamente de realizar una buena recomendación a sus clientes, optimizar el funcionamiento de estos sistemas de recomendación resulta una tarea muy importante. Si bien los sistemas clásicos funcionan bien en términos generales, a cada empresa le interesa que su sistema se comporte de forma correcta en su ámbito, y es en estos detalles donde más interesantes son las mejoras. Y es que para una multinacional, una mejora en sus recomendaciones de un mero 1 % (que puede parecer ínfima) resulta en una inyección de ingresos muy sustancial.

Este estudio analizará uno de los ámbitos más comunes, las **recomendaciones de películas**. Como principal ejemplo, la plataforma de ocio audiovisual **Netflix** es una de las más utilizadas del momento, cuenta con un sistema de recomendación de películas y series muy elaborado, y sin embargo, solo es capaz de recomendar **para un único usuario**. No solo en el ámbito de las películas, sino en casi cualquiera, generalmente las recomendaciones se hacen de forma individual, y hay que buscar un sistema especializado si se quiere recomendar a un grupo de personas. Existen multitud de implementaciones de **sistemas de recomendación a grupos** que tratan de optimizar la elección para satisfacer lo máximo posible a todos los miembros del grupo, o al menos lograr un equilibrio. Este trabajo se esforzará en estudiar las soluciones más actuales a este problema y cómo han mejorado lo que ofrecen las soluciones más clásicas, enmarcadas en el ámbito de las películas.

1.2. Objetivos

Como se ha mencionado, ese Trabajo de Fin de Máster pone el foco en los sistemas de recomendación de películas a grupos. Existen múltiples soluciones a este problema, que han ido mejorando con el paso de los años y el progreso logrado mediante investigación. En este estudio se pondrá especial atención en aquellos más recientes, que en esencia serán los que aúnen de forma más eficiente dichos progresos. Una vez estudiados algunos de estos modelos, se tratará de crear una serie de versiones propias que mejoren lo existente.

El plan de ruta del trabajo será partir de un **modelo básico**, o *baseline*, que será el que marque el valor mínimo que debe tener el modelo propio implementado. Se entiende que un modelo peor que un baseline jamás debe ser considerado como bueno, ya que se trata de algoritmos altamente probados y contra numerosas situaciones distintas, y que funcionan bien en términos generales.

Con el modelo básico seleccionado, se procederá a realizar una investigación en la literatura, descubriendo cómo se ha producido la evolución en el

campo de los sistemas de recomendación a grupos, cuáles son las propuestas más innovadoras en los últimos años y, principalmente, cuáles han dado un mejor resultado. Entre estas últimas se seleccionará una entre las más recientes y las que más interesantes y adaptables resulten de cara a futuras modificaciones.

Habiendo elegido un modelo baseline y un modelo actual, el siguiente paso será implementarlos. Se tratará de ajustar lo máximo posible a la información recabada en los *papers* de los algoritmos, para ser fiel a la implementación original de los autores. Por desgracia, ninguna de las versiones más modernas y funcionales es de código abierto y es imposible encontrar una implementación que no haya sido creada a interpretación del *paper*.

Una vez se hayan implementado los dos modelos, se crearán una serie de nuevas soluciones que pongan en práctica lo aprendido durante el estudio en la literatura y las ideas surgidas al mismo tiempo. Se tratará de adaptar el modelo actual en la medida de lo posible, pero utilizando las nuevas técnicas que se crea que puedan suponer un incremento en la eficacia del método.

Por último, con todas las implementaciones hechas, se realizará un estudio experimental donde se pondrán a prueba todos los sistemas de recomendación bajo diferentes circunstancias y parámetros. Se recogerán los datos y posteriormente se evaluará cuál es la mejor solución y si alguna de las soluciones ideadas para este trabajo han logrado mejorar lo existente.

Capítulo 2

Planificación

En este capítulo se aborda el plan de trabajo a seguir para la realización de este estudio. En primer lugar se realizará la captación de requisitos necesarios para lograr el objetivo propuesto, y después se detallará la planificación del trabajo, con una estimación en costes tanto de trabajo como de materiales así como una distribución del tiempo entre tareas.

2.1. Requisitos de investigación

Al tratarse de un trabajo de investigación, no se puede realizar adecuadamente el análisis de requisitos habitual para un proyecto general de ingeniería. En su lugar, sin embargo, se plantean unos objetivos diferentes que se deben cumplir para llevar a cabo un estudio de estas características. En el caso de este estudio en particular, los requisitos que se pueden plantear son los siguientes:

1. **Realizar una investigación inicial en torno a los sistemas de recomendación:** revisar la literatura buscando información acerca de estos sistemas, comprobar qué evolución han seguido a lo largo de los años y cómo se han llegado a desarrollar los sistemas de recomendación a grupos.
2. **Profundizar en el estado del arte del sistemas de recomendación a grupos:** investigar más a fondo en estos métodos que son en los que realmente se va a centrar el estudio. Obtener los sistemas más destacados del estado del arte.
3. **Seleccionar el algoritmo de referencia del estado del arte:** Entre todos los sistemas de recomendación a grupos que se hayan investigado en el paso anterior, decidir cuál es el que se ajusta mejor a

los requerimientos del estudio y obtener toda la información necesaria para implementarlo.

4. **Diseñar el experimento:** crear los grupos para la experimentación e implementar un algoritmo *baseline* que sirva como punto de referencia. Implementar las estrategias de agregación de soluciones a la hora de experimentar y comprobar su correcto funcionamiento con dicho algoritmo.
5. **Implementar el algoritmo del estado del arte:** implementar el método siguiendo los parámetros y estructura del experimento diseñado. Es necesario contar con el código de los algoritmos para el experimento, por lo que hay que implementar el del estado del arte si no se puede conseguir su código fuente.
6. **Diseñar las nuevas propuestas del estudio:** para el objetivo del estudio hay que plantear nuevas propuestas que puedan competir con el estado del arte. Para ello primero hay que valorar los campos que quedan por experimentar y proponer una serie de algoritmos que se ajusten al perfil buscado.
7. **Implementar las propuestas propias:** una vez decididas las propuestas que van a formar parte del experimento, se deben implementar del mismo modo que el algoritmo del estado del arte. Comprobar de nuevo que toda la funcionalidad del experimento es válida con la nueva implementación.
8. **Obtención de resultados:** obtener a través de la implementación del experimento los resultados del mismo. Se pueden visualizar los datos con tablas y gráficos que sean adecuados para el estudio.
9. **Estudio analítico de los resultados obtenidos:** comparar los resultados de cada método con el método de referencia *baseline* y con el método del estado del arte, así como entre ellos, a fin de descubrir qué algoritmo se comporta mejor para cada caso, tanto entre grupos formados de distinta forma como con estrategias de agregación diferentes.
10. **Extraer conclusiones del estudio realizado:** dar una visión analítica de la eficacia de las propuestas ideadas para el estudio, apoyándose en los resultados obtenidos con respecto a los algoritmos de referencia, y justificar cuáles de ellas son más prometedoras.
11. **Trabajos futuros a realizar:** valorar en qué aspectos se puede seguir progresando en los métodos propuestos en el estudio, así como proponer nuevas tareas o retos dentro de este ámbito de investigación que no se hayan abarcado en el proceso del mismo.

Con los requisitos planteados, la planificación del trabajo debe ocupar los pasos que se han definido y estimar un tiempo con el que se podría solventar cada requisito. Además, debe describir todo el material e infraestructura necesarios y, junto al tiempo estimado, dar una idea del presupuesto que requiere realizar este estudio.

2.2. Planificación del trabajo

Este apartado está subdividido en la estimación de costes y la estimación de tiempo. Es necesario en un primer momento valorar el coste de la infraestructura y de todo aquel material que no esté disponible de forma libre o gratuita, y saber de qué presupuesto inicial debe partir el estudio. Además, la estimación de tiempo debe ser competente y ser capaz de abarcar los mejores y peores casos prácticos, para que no sea necesario aplazar la entrega a última hora debido a una mala planificación, y deberá influir a su vez en el coste, pues es un recurso más con el que se cuenta.

2.2.1. Estimación de coste de materiales e infraestructura

En primer lugar se tendrá en cuenta la máquina con la que se ha desarrollado el grueso de este estudio. Se trata de un ordenador portátil de la marca Acer, del año 2012, y que cuenta con un procesador i5-2450M a 2.5GHz, así como con 8GB de memoria RAM DDR3, un HDD de 1TB y un SSD de 120GB, que ha sido añadido posterior a la compra del equipo. Con este equipo se han realizado aquellas tareas de documentación, revisión de la literatura y redacción de la memoria, así como las labores de desarrollo e implementación de los algoritmos.

Para obtener la información y documentación requerida para el trabajo ha sido necesaria una red de internet de banda ancha, disponible tanto en el lugar de desarrollo del trabajo como en las instalaciones de la Universidad de Granada cuando ha sido necesario. Gracias a los convenios que la Universidad establece con algunas bases de datos documentales como Scopus [?] ha sido posible acceder a multitud de *papers* y publicaciones sobre el tema a investigar. Además ha sido de mucha utilidad la página ResearchGate [?] para acceder a otros papers no encontrados en Scopus.

El desarrollo del trabajo ha sido realizado completamente sobre el sistema operativo Linux, con una distribución Ubuntu 17.10, por lo que es totalmente libre y carente de costes. Las principales herramientas de software utilizadas también han sido de código abierto por lo que no han conllevado coste adicional, utilizando como IDE principal Visual Studio Code [?] y escribiendo la memoria en LaTeX utilizando el software TeXstudio [?].

Para la ejecución de los experimentos, debido al procesador antiguo del ordenador principal, así como de los grandes cálculos que son necesarios para la experimentación, el departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada (DECSAI) facilitó el acceso a su clúster Hércules [?], ubicado en el Centro de Investigación en Tecnologías de la Información y de las Comunicaciones de la Universidad de Granada (CITIC-UGR). Este clúster, de acuerdo a la fuente anteriormente citada, «posee 46 nodos, cada uno de ellos equipado con un procesador Intel Core i7 930 a 2.8 GHz, 24 GB de RAM y HDD SATA2 de 1TB. Los nodos están interconectados mediante dos redes internas de tipo Gigabit Ethernet. El sistema incluye una cabina RAID con capacidad para 72 TB. Se emplean los S.O. Fedora 16 y CentOS 6.2». Se trata por tanto de una máquina mucho más potente que la utilizada en el estudio, y servirá para obtener de forma más eficaz los resultados de los experimentos.

De todo este material expuesto en los párrafos anteriores, el trabajo sólo ha requerido comprar el ordenador portátil personal y la red de banda ancha disponible en el lugar de desarrollo del mismo, dado que se trata de recursos personales. El resto de la infraestructura y materiales o bien han sido productos de software libre o han sido aportados por la Universidad de Granada.

2.2.2. Distribución de tiempo entre tareas

Organizar la carga de trabajo en las distintas fases del proceso es una labor que debe realizarse antes del comienzo del mismo. Gracias a ello se pueden plantear fechas de entrega, acotar los tiempos dedicados a cada tarea y, por consiguiente, ayudar al rendimiento general del problema.

En primer lugar, la labor de revisión de la literatura y documentación abarcará todo el proceso, ya que es habitual que a lo largo del desarrollo sea necesario acudir a nuevos documentos que contengan la información deseada. Sin embargo, de la primera tarea se dedicará una semana a seleccionar las propuestas más interesantes a priori, una vez conocidos los principales algoritmos. En dicha labor, cabe destacar la ayuda de este «bestiario» de algoritmos evolutivos recopilado por el usuario *fcampelo* en la plataforma GitHub [?], que ha servido para descubrir algunos de los algoritmos escogidos para el estudio.

En cuanto a la comprensión de cada algoritmo y la implementación del mismo, resulta una tarea compleja y que tiene una alta carga de trabajo. A pesar de que estos algoritmos no están necesariamente plagados de complejas fórmulas matemáticas, sí que es necesario escudriñar a fondo toda la información recabada de su definición en la literatura, a fin de poder realizar una implementación adecuada del mismo. Una estimación factible es que

comprender e implementar cada algoritmo puede llevar entre dos semanas y un mes, dependiendo de la complejidad del mismo.

Antes de plantear los experimentos definitivos se ha propuesto realizar una estimación de parámetros, debida a la poca información que algunos de los *papers* esclarecen acerca de los mismos. Esto llevará un par de semanas para elegir el benchmark, preparar el entorno de trabajo y ejecutar los algoritmos. Lógicamente, cuantas más combinaciones de parámetros se quieran probar, más extenso será este tiempo.

La experimentación final requerirá de unos días más para seleccionar dichos parámetros adecuadamente, preparar una serie de scripts que lanzar en paralelo y recopilar los datos de forma conjunta. Una vez conseguido esto, la construcción de tablas y gráficas será también casi directa, aunque trabajosa, y puede llevar otra semana.

Finalmente, extraer conclusiones de los resultados puede ser más sencillo si se conocen los algoritmos y se han trabajado correctamente, de forma que sea fácil interpretarlos y descubrir patrones en los mismos. Al ser una tarea tan diversa y poco acotada, una extracción de conclusiones puede llevar desde una semana hasta más de un mes.

En resumen, la ruta de trabajo trazada por estas tareas puede estimarse en que llevará entre unos 6 y 7 meses, aunque naturalmente ese espacio de tiempo puede variar dependiendo de lo que se invierta cada día. Es de importancia recordar que el coste del tiempo invertido también debe ser igualmente valorado tal y como se hace con el coste de los materiales. Partiendo de la base de que este estudio es, en esencia, un trabajo de investigación en un campo puntero tecnológicamente, podría estimarse el coste total del trabajo como una media entre el sueldo a jornada completa de un ingeniero informático y el de un investigador de un departamento de universidad durante el transcurso del mismo.

Siendo un valor estimado de 18 euros/hora para una profesión como esta, a 6 meses trabajando (20 días al mes) a 8h diarias, se estipularía el presupuesto del proyecto en 17280 euros.

Capítulo 3

Revisión de la literatura: estado del arte

En este capítulo se expondrá una revisión de los estudios y propuestas más innovadoras relacionadas con los **sistemas de recomendación a grupos**, y en particular, de aquellos orientados al ámbito de las películas. Se comenzará haciendo un breve inciso sobre cuándo y cómo se originaron los sistemas de recomendación, así como la particularidad de aquellos específicos de recomendación a grupos. Después se tratará su evolución hasta nuestros días, realizando un comentario analítico acerca de lo que han supuesto los sistemas de recomendación y cómo se trasladan actualmente dichos sistemas a situaciones cotidianas, con algunos claros ejemplos que todo el mundo utiliza. Entre ellos se destacarán los que abarcan la **recomendación de películas**, como tema principal del estudio. Por último, se mencionarán algunos de los sistemas de recomendación de películas a grupos más actuales, eligiendo además el que será tomado como referencia para la experimentación como representante del estado del arte de estos recomendadores.

3.1. Análisis de la literatura

3.1.1. Historia de los sistemas de recomendación

Queda ya muy atrás el primer sistema de recomendación de la historia, que vio la luz en 1992, cuando Goldberg et al. (1992) presentaron su artículo *“Using collaborative filtering to Weave an Information tapestry”* [1]. En este trabajo se acuña por primera vez el término **“filtrado colaborativo”** (en inglés, *collaborative filtering*), refiriéndose así a la técnica que permite filtrar elementos a un usuario basándose en lo que otros usuarios han opinado de él

anteriormente. Esta técnica sienta las bases de los sistemas de recomendación, y aún a día de hoy se encuentra presente en la mayoría de ellos. La otra alternativa al filtrado colaborativo es el **filtrado basado en contenido** (en inglés, *content-based filtering*). Esta técnica no tiene en cuenta las valoraciones que otros usuarios han dado a los elementos del sistema, sino que se limita a comparar los elementos por características y recomendar aquellos similares. En este experimento, sin embargo, se tratarán únicamente métodos que utilizan el filtrado colaborativo.

Una vez se hubo contemplado el vasto rango de opciones que albergaban los sistemas de recomendación, a través de numerosos trabajos y estudios, se contempló la posibilidad de recomendar ya no solo a individuos, sino a grupos de personas. Se trataba de una situación a la que una sociedad podía enfrentarse en multitud de facetas, y que sin duda merecía la pena explorar. La pionera, y una de las más famosas y reconocidas propuestas sobre este tema, fue **PolyLens** [2]. En esta publicación de 2001, O'Connor et al. plantearon **un sistema de recomendación de películas para grupos**, derivado de la base de datos de valoraciones de películas **MovieLens**, en la que varios trabajos anteriores se habían fundado. Este sistema abrió la veda de un nuevo subgrupo dentro de la ya amplia categoría de sistemas de recomendación.

Como se ha comentado anteriormente, las recomendaciones a películas han levantado mucho interés desde el primer momento. El contenido de ocio audiovisual, junto a los catálogos de tiendas *online*, son los casos de mayor demanda en cuanto a sistemas de recomendación en la sociedad actual. Plataformas como **Netflix**, **Spotify** o **HBO** son ejemplos de los primeros, que utilizan estos sistemas para tratar de mantener al usuario satisfecho ofreciéndole nuevo contenido que sea similar al que hayan visto. Por su parte, **Amazon** o **AliExpress** son ejemplos de los segundos, grandes plataformas que dan cabida a todo tipo de productos y que son capaces de recomendar a sus clientes otros productos similares a los que están buscando. Gracias al sistema de recomendación pertinente, incluso consiguen ofrecer nuevos artículos que detectan que el usuario puede querer comprar, basándose en lo que anteriormente ha buscado o comprado.

Tal fue el impacto de los sistemas de recomendación que la propia plataforma Netflix lanzó en 2006 lo que se conocería como el **Netflix Prize** [3], una competición de sistemas que, basándose únicamente en el filtrado colaborativo (no conociendo datos adicionales sobre películas ni sobre usuarios, solamente las valoraciones que estos habían dado a cada película) fueran capaces de predecir acertadamente dichas valoraciones. El objetivo principal era superar al por aquel entonces actual sistema de recomendación de Netflix, conocido como **Cinematch**, ofreciendo un premio de 1 millón de dólares a aquel sistema capaz de superarlo en un 10 %. Adicionalmente,

como la competición se estimaba que duraría hasta 2011, se concedería un premio anual de 50.000 dólares al método ganador al final de cada año.

Tras varios tira y afloja entre algunos equipos, e incluso agrupaciones entre equipos para forjar mejores ideas juntos, finalmente en 2009 el equipo *'BellKor's Pragmatic Chaos'* se alzó ganador y recibió el gran premio [4], superando al algoritmo anterior por 10.05 %. De esta forma tan original Netflix cambió su sistema de recomendación promoviendo una iniciativa de investigación en este campo, y por supuesto previendo que este avance en su algoritmo les serviría para incrementar la satisfacción de sus clientes, y por ende, para aumentar su valor de mercado.

3.1.2. Recomendación a grupos en la actualidad

Tras haber sido puestos en el panorama de investigación con casos como el Netflix Prize y el evidente aumento de su uso conforme las nuevas tecnologías se han vuelto más accesibles para la sociedad, los sistemas de recomendación han contemplado un gran abanico de variedades: algunos más enfocados a la materia que recomendar (por ejemplo, sistemas de recomendación de música o de películas), otros enfocados al tipo de usuario (sistemas de recomendación individual o a grupos) e incluso algunos cuyo propósito no es solamente obtener el mejor resultado (sistemas de recomendación explicativos que sirvan de apoyo a una decisión).

Como el objetivo de este trabajo es orientarse en recomendación a películas para grupos de usuarios, la búsqueda en la literatura de algoritmos que apoyasen el estudio se focalizó en estos dos grandes campos, analizando algunas propuestas de la última década. La recomendación a grupos ha avanzado a muchos niveles desde la presentación de PolyLens, y ahora existen varios frentes abiertos en investigación sobre este tema.

Uno de las primeras fuentes que se recopilaron sobre los sistemas de recomendación a grupos, y que han servido a este estudio para obtener información general sobre los mismos, es el capítulo de Masthoff en el *Recommender Systems Handbook* de 2011 [5], donde hace un repaso a los campos de investigación abiertos de los que se hablaba en el párrafo anterior, y realiza un análisis sobre los pasos a seguir en adelante. Masthoff sienta en primer lugar los motivos por los que es necesario contar con sistemas de recomendación a grupos frente a la recomendación individual que ya se había trabajado más de una década. Aporta una detallada recopilación de las estrategias de agregación que utilizaban los sistemas de recomendación a grupos más interesantes de la época, como el ya mencionado PolyLens [2], el sistema MusicFX [6] que determina la emisora de radio que suena de fondo en un gimnasio en función de los gustos de la gente que haya ejercitándose en ese momento, o el sistema Intrigue [7] que ayuda a grupos de turistas a deci-

dir qué visitar, entre otros. A continuación explica cómo se pueden aplicar los algoritmos de recomendación a grupos para usuarios individuales, dando a entender que estos algoritmos son reutilizables dependiendo del contexto en el que se necesiten. Termina planteando una serie de retos a los que los sistemas de recomendación a grupos se enfrentaban en aquel momento: aportar explicaciones a las recomendaciones propuestas, profundizar en el “problema del inicio frío” para grupos de usuarios o recomendar ítems en un determinado orden.

En el contexto de las recomendaciones ordenadas podrían englobarse los **rankings**, que es hacia donde han evolucionado los recomendadores individuales en las principales páginas de Internet. Es habitual no limitarse a recomendar un único ítem a un usuario, lo que propicia que se investigue en recomendar series de elementos dándoles un determinado orden (por supuesto, se quiere colocar en primer lugar aquel que se prediga que va a tener más aceptación).

Una publicación parecida a la de Masthoff en términos de recopilación, pero más reciente, fue la que realizaron Dara et al. en 2019 [8]. En este trabajo, titulado *A survey on group recommender systems*, ofrecen una nueva perspectiva más actual del estado del arte de los sistemas de recomendación a grupos. Una de las distinciones que hace en cuanto a estos recomendadores es acorde al ámbito en el que se desarrollan: películas, música, viajes o programas/cadenas de televisión. De acuerdo al tema de este estudio, tienen más interés aquellos relacionados con las películas. Además del ya conocido PolyLens, que ya era el principal recomendador de películas a grupos cuando Masthoff et al. desarrollaron su estudio, añade otros diez recomendadores más actuales, de la década de los 2010s. Entre ellos, aparecen dos publicaciones de 2017, las más recientes de la lista, y que podrían entrar en el debate del estado del arte de estos sistemas.

Una de ellas es **OrderedRec**, de Agarwal et al. [9], donde plantean solución a uno de los retos que planteaba Masthoff en su publicación de 2011: las recomendaciones ordenadas. Partiendo de un determinado orden de preferencia de cada usuario, introducen la satisfacción del mismo como atributo, que es calculado en función de la diferencia entre sus preferencias y el orden calculado por el recomendador.

La otra es **Natural Noise Management (NNM)** de Castro et al. [10]. En esta publicación se analiza el caso en el que el usuario aporte sus preferencias explícitamente pero puedan encontrarse inconsistencias debido a lo que se conoce como **ruido natural**. El estudio consiste en tratar de modelar el ruido natural de forma que sea capaz de detectarse sin afectar al rendimiento general del algoritmo de por sí.

Una última aportación que se menciona de 2017 es el caso del recomendador **HappyMovie** [11]. La primera publicación de este sistema es en 2011,

cuando Quijano-Sánchez et al. idean una aplicación capaz de recomendar películas a grupos de usuarios en la red social Facebook. En primera instancia, mediante un test de personalidad la aplicación pide a los usuarios que la van a utilizar que valoren una serie de películas, para así obtener información del usuario y solventar en cierta manera el conocido problema del “inicio frío”. A continuación, a través de los datos de Facebook obtiene la “confianza” que tienen unos usuarios con respecto a otros, para detectar cómo influye cada uno en su recomendación particular. Además, utiliza memoria en el tiempo para mejorar las recomendaciones, no recomendar las mismas películas, y sobre todo, introduce el concepto de “fairness”, para tratar de hacer recomendaciones justas y que todo el mundo esté contento.

Este sistema alcanza una nueva cota en 2017, cuando para el artículo “*Make it personal: A social explanation system applied to group recommendations*” [12] Quijano-Sánchez et al. añaden una nueva dimensión de **explicación en las recomendaciones**. Mediante esta mejora, que a primera vista puede resultar menos influyente de lo que realmente es, consiguen darle a los usuarios una sensación de confianza. Un usuario puede necesitar una explicación cuando se le va a recomendar una película que no le va a gustar pero sin embargo es necesaria para el grupo en un determinado momento, bien sea porque dicho usuario ha visto una serie de películas seguidas que le han gustado más que al grupo o por algún otro motivo distinto. También se especifica la posibilidad de que en grupos de más de cuatro miembros solo se dará una explicación detallada sobre la influencia de los tres más cercanos al usuario que pide la explicación, y sobre el resto se hace un resumen. Posibilitar esto mejora la confianza del usuario en el sistema, y por ende, se ve más propenso a depositar sus elecciones futuras en manos del recomendador.

Una vez situados los sistemas de recomendación a grupos en el panorama de investigación, habiendo comprendido su evolución y su progreso en el tiempo y dónde se encuentran ahora mismo, el objetivo del trabajo era encontrar una propuesta actual (a ser posible, de 2019) que hiciera de referencia a batir para el estudio. El principal requisito que se le pedía a dicha propuesta era que representase bien el estado del arte planteando una idea innovadora y que resultase intuitiva desde el punto de vista algorítmico. Debido a la naturaleza de las nuevas aportaciones que se plantean en este estudio, que buscan automatizar mediante su algoritmo algunas tomas de decisiones que podrían llevarse a cabo tras consenso pactado entre los propios miembros del grupo, era especialmente interesante encontrar una publicación del estado del arte que aportase esta misma condición.

Buscando propuestas de los dos últimos años para el estudio se encontraron una serie de ellas que, pese a pertenecer al ámbito de las películas, no resultaron adecuadas para el estudio por no contar con el factor anteriormente mencionado de “algoritmo comprensible”. Presentado en 2019,

el método “*Evolutionary learning approach to multi-agent negotiation for group recommender systems*” de Choudhary y Bharadwaj [13] plantea una especie de algoritmo genético que trabaja con multiagentes dentro del grupo. Mediante funciones de mutación y cruce se van generando nuevas soluciones que pueden o no mejorar a lo que existía anteriormente, como si de una metaheurística se tratase. En este método en particular, además se incluyen unas técnicas de negociación entre soluciones para llegar a un punto intermedio, lo que al fin y al cabo sería un pseudo-operador de cruce. Dada la necesidad de incluir algoritmos genéticos en el desarrollo de la solución, esta se distancia del perfil que se andaba buscando para el método de referencia del estado del arte. Lo mismo ocurre con la publicación “*Recommender system with grey wolf optimizer and FCM*” de Katarya y Verma, que a pesar de ver la luz por primera vez a través de Internet en 2016, fue publicado en la revista *Neural Computing and Applications* en septiembre de 2018 [14]. Este método sigue una estructura similar al de Choudhary y Bharadwaj, pero en lugar de utilizar algoritmos genéticos utiliza en su lugar algoritmos bioinspirados. En particular, mediante el *Grey Wolf Algorithm*, uno de los bioinspirados más conocidos, busca “acorralar” a través de una serie de iteraciones la mejor solución posible dada la población (miembros del grupo) de la que dispone.

3.2. Propuesta del estado del arte escogida

Después de haber buscado de forma extensiva a lo largo de la historia de los sistemas de recomendación a grupos, y tras haber indagado en las publicaciones de los últimos años en particular, una idea llamaba la atención sobre el resto; habiendo realizado el autor de este trabajo un estudio anterior acerca de las **metaheurísticas socioinspiradas** (basando su algoritmo en comportamientos propios de la sociedad humana), resultaba interesante plantear por qué no existían apenas soluciones que trataran de llevar al algoritmo el mismo comportamiento que los propios humanos llevan a cabo a la hora de sus tomas de decisiones. Ya que en general los humanos adaptan sus métodos a lo que comprueban que funciona mejor o peor, se plantea en este estudio un abanico de posibilidades partiendo de este antecedente. Y es por dicha razón que la propuesta del estado del arte escogido debía de tener alguna relación con este tipo de metodología.

Una vez estudiados los algoritmos más recientes, existe uno de ellos que se adapta a este esquema mejor que ningún otro. Publicado en 2018, pero presentado en se trata del método “*Preference-Oriented Group Recommender System*” de Choudhary y Bharadwaj [15]. En palabras de los propios autores, “el principal objetivo de un sistema de recomendación a grupos es identificar las preferencias de cada usuario y encontrar un punto de conce-

sión en el que todos los usuarios se encuentren igualmente de acuerdo”. Este objetivo normalmente supone un reto muy complejo de conseguir, dadas las potenciales preferencias enfrentadas que puedan ocurrir entre los miembros del grupo y que den lugar a puntos intermedios nada satisfactorios para el resto de los usuarios.

Tradicionalmente se ha optado por generar un “perfil de usuario” como resultado de la agregación de las distintas preferencias de los usuarios, o bien se han ido agregando recomendaciones hechas a miembros individuales del grupo para comprobar cuál es la más exitosa. En este trabajo, Choudhary y Bharadwaj proponen una solución, el **recomendador POGRS**, que se acerca más a la primera opción, y que busca obtener un perfil de usuario que simbolizará al grupo y al que se le realizará la recomendación “individual”. Lo que distingue este caso de otros es que, para este método, el perfil del grupo no es generado mediante agregación de preferencias, sino que es **un usuario propiamente del grupo**. Este pequeño cambio de concepto acerca más el algoritmo a un prototipo socioinspirado, donde se puede prescindir de tener un sujeto abstracto y simplemente trabajar con los propios usuarios.

Para escoger quién es el usuario que más representa al grupo, el método calcular una nueva variable que denomina “estatus del usuario” y que mide el grado de representación de cada uno con respecto al grupo. Para calcularlo, en primer lugar se debe conocer los tres elementos preferidos de cada miembro del grupo, a saber: primero, el más preferido (MP); segundo, el preferido (P); y tercero, el menos preferido (LP). El estatus del usuario consiste en calcular cuántos otros usuarios apoyan su primera elección, su segunda y su tercera. Como es lógico, teniendo más influencia en el resultado final que dos coincidan en el primer elemento a que coincidan en el tercero.

El cálculo final del estatus de un usuario consiste en la sumatoria de los apoyos al primer, segundo y tercer elemento de su lista de preferencias por parte del resto de miembros del grupo. Una vez obtenido el estatus se puede saber qué usuario es el más representativo del grupo y por ende, hacer como recomendación grupal la **lista de preferencias de dicho usuario**. De cara a interpretarlo como carácter social, podría decirse que este algoritmo se asemeja a una votación popular, en la que los miembros del grupo aportan su lista de elementos preferida y en base a una cierta mayoría a lo largo de dicha lista se decide cuál está más cerca del hipotético perfil agregado de todos los usuarios.

Bibliografía

- [1] D. Goldberg, D. Nichols, B.M. Oki, and D. Terry. Using collaborative filtering to Weave an Information tapestry. *Communications of the ACM*, 35:61–70, 1992.
- [2] M. O'Connor, D. Cosley, J.A. Konstan, and J. Riedl. PolyLens: A Recommender System for Groups of Users, 2001.
- [3] Netflix Prize. <https://www.netflixprize.com/>.
- [4] Netflix Prize Forum: Grand Prize awarded to team BellKor's Pragmatic Chaos. https://www.netflixprize.com/community/topic_1537.html.
- [5] J. Masthoff. Group recommender systems: Combining individual models. *Recommender Systems Handbook*, pages 677–702, 2011.
- [6] J.F. McCarthy and T.D. Anagnost. MusicFX: An Arbiter of Group Preferences for Computer Supported Collaborative Workouts. In *Proceedings of the 1998 ACM Conference on Computer Supported Cooperative Work*, CSCW '98, pages 363–372, New York, NY, USA, 1998. ACM.
- [7] L. Ardissono, A. Goy, G. Petrone, M. Segnan, and P. Torasso. Intrigue: personalized recommendation of tourist attractions for desktop and handset devices. *Applied AI, Special Issue on Artificial Intelligence for Cultural Heritage and Digital Libraries*, 17(8-9):687–714, 2003.
- [8] S. Dara, R. Chowdary, and C Kumar. A survey on group recommender systems. *Journal of Intelligent Information Systems*, January 2019.
- [9] A. Agarwal, M. Chakraborty, and R. Chowdary. Does order matter? Effect of order in group recommendation. *Expert Systems with Applications*, 82:115–127, October 2017.
- [10] J. Castro, R. Yera, and L. Martinez. An empirical study of natural noise management in group recommendation systems. *Decision Support Systems*, 94:1–11, February 2017.

- [11] L. Quijano-Sánchez, J. Recio-García, B. Díaz-Agudo, and G. Jiménez-Díaz. Happy Movie: A Group Recommender Application in Facebook. *Proceedings of the 24th International Florida Artificial Intelligence Research Society, FLAIRS - 24*, January 2011.
- [12] L. Quijano-Sánchez, C. Sauer, J. Recio-García, and B. Díaz-Agudo. Make it Personal: A Social Explanation System Applied to Group Recommendations. *Expert Systems with Applications*, 76, January 2017.
- [13] N. Choudhary and K.K. Bharadwaj. Evolutionary learning approach to multi-agent negotiation for group recommender systems. *Multimedia Tools and Applications*, 78:16221–16243, 2019.
- [14] R. Katarya and O.P. Verma. Recommender system with grey wolf optimizer and FCM. *Neural Computing and Applications*, 30:1679–1687, September 2018.
- [15] N. Choudhary and K.K. Bharadwaj. Preference-Oriented Group Recommender System. *Applications of Artificial Intelligence Techniques in Engineering. Advances in Intelligent Systems and Computing*, 698:581–589, 2018.

